

# یادگیری ساختار شبکه بیزی با محدودیت‌های جانبی

Andrew C. Li    [ACLI@UWATERLOO.CA](mailto:ACLI@UWATERLOO.CA)  
Peter van Beek   [VANBEEK@CS.UWATERLOO.CA](mailto:VANBEEK@CS.UWATERLOO.CA)  
Cheriton School of Computer Science  
University of Waterloo

## چکیده

روش‌های ترکیبی برای یادگیری ساختار شبکه بیزی که هم داده‌های مشاهده شده و هم دانش تخصصی را در بر می‌گیرد در بسیاری از زمینه‌ها مهم است. مطالعات قبلی هر دو روش دقیق و تقریبی را برای یادگیری ساختار ارائه کرده‌اند. در این مقاله، ما یک روش تقریبی مبتنی بر جستجوی محلی پیشنهاد می‌کنیم که توانایی مدیریت موثر انواع محدودیت‌های دانش قبلی را دارد، از جمله یک طبقه مهم از محدودیت‌های اجدادی غیرقابل تجزیه است که دلالت بر علیت غیر مستقیم بین متغیرهای تصادفی دارند. در آزمایش‌ها، روش تقریبی پیشنهادی ما می‌تواند به طور قابل توجهی بهتر از روش تقریبی موجود در یافتن راحل‌های عملی در زمانی که محدودیت‌های سخت اعمال می‌شوند، عمل کند. رویکرد ما قادر به یافتن شبکه‌های بهینه نزدیک در حالی است که تقریباً ۵۰ متغیر تصادفی را در بر می‌گیرد. در مقابل، روش‌های دقیق قبلی قادر به کنترل بیش از بیست متغیر تصادفی نیستند. علاوه بر این، ما نشان می‌دهیم که وقتی دانش قبلی ادغام می‌شود، ما اغلب قادر به تولید یک شبکه بسیار نزدیک‌تر به شبکه واقعی (شبکه واقعیت زمینی ground truth network) هستیم، به خصوص وقتی که مقدار داده محدود باشد.

## 1. معرفی

**شبکه بیزین (BN):** یک مدل گرافیکی احتمالاتی از توزیع احتمال با کاربردها در زمینه‌های مختلف است. در عمل معمولاً به طور کامل توسط یک متخصص مشخص شده و یا مستقیماً از داده‌های مشاهده‌شده یاد گرفته می‌شود؛ با این حال، هر دو روش دارای اشکالات عمده هستند. متخصصین معمولاً دامنه دانش کافی برای تولید شبکه کاملاً ندارند، به خصوص که تعداد متغیرهای تصادفی افزایش یابد. از سوی دیگر، وظیفه یادگیری ساختار BN مستقیماً از داده‌ها، یک مسأله hard-NP است، حتی برای رسیدن تقریبی به یک فاکتور منطقی داده‌ها اغلب محدود یا پرهزینه هستند.

### 1.1. محدودیت‌های دانش تخصصی

در بسیاری از زمینه‌ها، روش‌های هیبریدی برای یادگیری ساختار BN که هم دانش و هم داده‌های تخصصی را در بر می‌گیرد برای به دست آوردن نتایج برتر اعمال شده‌است؛ به عنوان مثال فلورس و همکاران (2011) و antal و همکاران (2004) و همکاران (2004) و oyen و همکاران (2016). این مطالعات از روش‌های جستجوی تقریبی با priors آموزنده استفاده می‌کنند، که به یک متخصص اجازه می‌دهد تا سطوح اعتماد را در محدودیت‌های مختلف مشخص کند. در مقابل، ما بر استفاده از دانش قبلی به عنوان محدودیت‌های سخت تمرکز می‌کنیم. روش ما بر روی MINOBS، یک الگوریتم جستجوی محلی مبتنی بر جستجوی محلی برای یادگیری ساختاری BN توسط Lee و vanbeek (2017) ساخته شده‌است. ما قادر به رسیدگی به انواع زیر از محدودیت‌های موجود در روش خود هستیم.

- (1) وجود یک یال: ادعا میکند که یک یال جهتدار وجود دارد. همچنین کاربر می‌تواند مشخص کند که یک یال بدون جهت  $x-y$  در صورتی وجود دارد که جهت شناخته نشود.
- (2) نبود یال: ادعا می‌کند که یال  $x-y$  وجود ندارد.
- (3) قید و شرط: ادعا می‌کند  $x$  قبل از  $y$  در برخی مرتب کردن گره‌ها در شبکه BN دیده می‌شود.
- (4) محدودیت اجدادی (مثبت): ادعا می‌کند که مسیری جهتدار بین  $x$  و  $y$  را وجود دارد.

ما به چنین محدودیت‌هایی به عنوان **محدودیت‌های جانبی** اشاره می‌کنیم. این محدودیت‌ها به اندازه کافی گویا هستند که به طور غیر مستقیم به برخی از محدودیت‌های رایج دیگر رسیدگی کنند؛ مانند نبود یال بدون جهت (نبود یال  $xy$  یا  $yx$ )، سطوح علیت یا سببی (فقط یال‌ها از متغیر ردیف پایین به یک متغیر ردیف بالاتر مجاز هستند) و مشخص کردن گره‌های ریشه و برگ‌ها. چالش اصلی کار ما، ترکیب محدودیت‌های اجدادی بود که نمی‌توان به صورت محلی (با اصلاح والدین یک گره) یا با هرس فضای مرتب‌سازی انجام داد. در فرآیند یادگیری ساختار به شدت مشکل پیچیده است. با این حال، محدودیت‌های اجدادی به چند دلیل مهم هستند: اول، اگرچه محدودیت‌های اجدادی ضعیف‌تر از محدودیت‌های ذاتی یال هستند ولی وابستگی‌های مستقیم تنها به درجه بالایی از دامنه دانش معطوف هستند لذا متخصصین احتمال بیشتری برای ارائه اطلاعات مفید دارند مخصوصاً در مواقعی که محدودیت‌های خاص کمتری نیز وجود داشته باشد.

ثانیا، محدودیت‌های اجدادی می‌توانند ادعا کنند که یک متغیر علت غیرمستقیم دیگری است، که شکل فراوانی از دانش تخصصی در بسیاری از حوزه‌ها دارد.

سوم این که این شبکه‌ها برای کشف دانش و یا ارائه دانش ساخته می‌شوند و باید همه وابستگی‌های علی شناخته شده را کدگذاری کنند. در آزمایش‌ها ما نشان می‌دهیم که اعمال محدودیت‌های اجدادی به شبکه واقعی (شبکه واقعیت زمینی *ground truth network*) در قالب اظهارات علی آن‌ها نزدیک‌تر است. در واقع، یادگیری ساختار BN از داده‌ها به تنهایی نمی‌تواند بین علیت و همبستگی تمایز قائل شود.

## 1.2. نتایج

ما یک روش یادگیری ساختار ترکیبی جدید را ارائه می‌کنیم که می‌تواند دانش کارشناسی را به عنوان محدودیت‌های سخت، از جمله محدودیت‌های اجدادی تولید کند. در ارزیابی تجربی ما نشان می‌دهیم که روش ما قادر به یافتن راحل‌های با کیفیت بالا برای مشکلات محدودیت‌هاست، در حالی که روش‌های دقیق قبلی قادر به کنترل بیش از بیست متغیر تصادفی نیستند. علاوه بر این، ما اولین کسانی هستیم که با موفقیت محدودیت‌های اجدادی را با رویکرد یادگیری ساختار BN مبتنی بر جستجو ادغام می‌کنیم.

## 1.3. کارهای مرتبط

ما به طور خلاصه برخی کارهای مرتبط با الگوریتم‌های یادگیری ساختار شبکه‌های بیزین را مورد بحث قرار می‌دهیم. در یک مقاله کلاسیک توسط Tsamardinos و همکارانش (۲۰۰۶)، از رویکرد greedy hill-climbing به طور موثر و دقیق برای یادگیری ساختار شبکه‌های بیزین استاندارد استفاده شد. یک الگوریتم جستجوی محلی دیگر توسط De و Castellano (۲۰۰۷) توانست دقیقاً به محدودیت‌های (۱) - (۳) رسیدگی کند. با این حال، این روش جستجوی محلی آنها مبتنی بر فضای DAGs است در حالی که روش پیشنهادی ما عمدتاً بر روی فضای Topological یا موضعی جستجو می‌کند.

یک رویکرد دقیق جدید توسط Chen و همکارانش (2016) به عنوان **درخت EC** به طور خاص برای رسیدگی به محدودیت‌های اجدادی طراحی شده بود. درخت EC نیز می‌تواند محدودیت‌هایی را بر عدم وجود مسیر هدایت کند و راحل‌هایی را با بهیئگی تضمین‌شده پیدا کند که روش پیشنهادی ما نمی‌تواند. با این حال، روش آن‌ها در مقایسه با ۲۰ متغیر تصادفی از لحاظ زمانی از امتیاز BDeu نیست. یک روش دیگر GOBNILP توسط Bartlett و Cussens (2017) است که یک رویکرد دقیق مورد استفاده گسترده و قادر به رسیدگی به انواع زیادی از محدودیت‌ها است. Chen و همکارانش (2016) ثابت کردند که GOBNILP را می‌توان برای رسیدگی به محدودیت‌های اجدادی هم انجام داد، اما نیازمند مرتبه بیشتری از درخت EC است.

روش CaMML که کشف تصادفی از طریق mml است و توسط Korb و Nicholson (۲۰۱۰) ارائه شده از جستجوی تصادفی براساس زنجیره مارکوف مونت کارلو استفاده می‌کند. این روش قادر به کنترل تمام محدودیت‌های (۱) - (۴) به جز محدودیت نبود یال است. همچنین می‌توانست ادعا کند که دو متغیر هم‌پسته اند و تمامی محدودیت‌ها را می‌توان به عنوان یک محدودیت نرم با تنظیم سطوح اعتماد مشخص نمود. ما CaMML را با روش پیشنهادی خود در ارزیابی تجربی و آزمایشات مقایسه می‌کنیم.

## 2. پیش نیاز ها

ما با مرور جزئیات مقدماتی در شبکه‌های بیز شروع می‌کنیم. یک شبکه‌های بیزین شامل  $n$  نود  $V = \{v_1, \dots, v_n\}$  که هر گره متغیر تصادفی است و یک توزیع احتمالی شرطی  $P(v_i | \text{par}(v_i))$  برای هر متغیر تصادفی  $v_i$  است که در آن  $\text{par}(v_i)$  احتمال مجموعه والدین  $v_i$  در  $G$  است. یال‌های  $G$  از یک‌گره به دیگری نشان‌دهنده وابستگی‌های مستقیم هستند و ساختار کامل  $G$  تمام وابستگی‌های شرطی بین متغیرها را کد می‌کند.

در این مقاله ما بر روی روش امتیازجستجو (score-search) برای یادگیری ساختار شبکه‌های بیزین تمرکز می‌کنیم. یک تابع امتیازدهی  $\sigma(G)$  انتخاب می‌شود که در آن هر DAG مانند  $G$  بر روی  $n$  متغیر را براساس میزان تناسب با داده‌های مشاهده شده تعیین امتیاز می‌کند (ما فرض می‌کنیم یک امتیاز پایین‌تر بهتر است). یکی از ویژگی‌های معمول اکثر توابع امتیازدهی مانند BIC/MDL و BDe، خاصیت تجزیه پذیری است به این معنی که امتیاز هر DAG مجموع نمرات محلی خود در هر گره است:

این روش معمول است که نمرات پیش فرض را برای هر متغیر تصادفی  $v_i$  و هر کدام از مجموعه نامزد های والد  $p \subseteq 2^{V \setminus \{v_i\}}$  محاسبه می‌کنند. شناسایی مجموعه پدر و مادر شامل هرس مجموعه پدر و مادر که هرگز ظاهر در راه حل‌های بهینه ساز نمی‌شود (بیشتر در بخش 3 بحث شده است). ساختار بهینه سازی، موظف به اختصاص یک پدر و مادر برای هر گره برای رسیدن به حداقل امتیاز شبکه بدون دور است. به منظور گنجاندن دانش قبلی، ما می‌خواهیم مشکل یادگیری ساختار شبکه‌های بیزین را با محدودیت‌های بیشتر حل کنیم. ما رسماً این مشکل را مطرح می‌کنیم که بر روی این مقاله تمرکز کنیم.

### تعریف ۱ (مشکل یادگیری ساختار شبکه بیزین) :

با استفاده از یک مجموعه داده  $D = \{d_1, \dots, d_N\}$  ، که در آن هر  $d_i$  یک بردار از مقادیر گسسته از ویژگی‌ها و متغیرهای تصادفی  $V$  است، یک تابع امتیازدهی  $\sigma$  نشان می‌دهد چگونه یک ساختار کاندیدا توسط داده‌های مشاهده شده  $D$  پشتیبانی می‌شود، و محدودیت‌های بسیاری از اشکال زیر را می‌سند:

1.  $x \rightarrow y$  (وجود یال جهت دار) یا  $x - y$  (وجود یال بدون جهت)

2.  $x \leftrightarrow y$  (نبود یال جهت‌دار)

3.  $x < y$  (محدودیت مرتب‌سازی موضعی (Topological)

4.  $x \sim y$  (محدودیت اجدادی)

مساله یادگیری ساختار شبکه بیزی محدود معطوف به یافتن گراف جهت‌دار و بدون دور  $G$  بر روی  $V$  که با توجه به موارد زیر امتیاز  $\sigma(G)$  را به حداقل برساند :

- برای هر گونه محدودیت  $x \rightarrow y$  ، یال  $xy$  در  $G$  است.
- برای هر محدودیت  $x - y$  ، یکی از یال‌های  $xy$  یا  $yx$  در  $G$  است.
- برای هر محدودیت  $x \leftrightarrow y$  ، یال  $xy$  در  $G$  نیست.
- ترتیبی چون  $O$  وجود دارد که برای تمام محدودیت‌های  $x < y$  که  $x$  قبل از  $y$  در  $O$  است و  $O$  یک مرتب‌سازی موضعی یا توپولوژیک برای  $G$  است.
- برای هر گونه محدودیت  $x \sim y$  ، یک مسیر جهت‌دار از  $x$  به  $y$  در  $G$  وجود دارد.

MINOBS جستجوی مبتنی بر مرتب‌سازی (Teyssier و Koller، ۲۰۰۵) را به یادگیری ساختار شبکه‌های بیزین اعمال می‌کند.

با توجه به یک مرتب‌سازی موضعی یا Topological برای مرتب کردن گره‌ها، پارامترهای بهینه سازگار با  $O$  را میتوان در زمان چند جمله‌ای پیدا کرد، با فرض اینکه مجموعه‌های والد اغلب محدود به یک اندازه ثابت در  $k$  هستند. این رویکرد در مرتبه زمانی  $O(n!)$  بر روی  $n$  متغیر جستجو را انجام می‌دهد، جاییکه در آن امتیاز یک مرتب‌سازی حداقل امتیاز یک شبکه‌های بیزین سازگار با این مرتب‌سازی است.

بقیه مقاله بر روی روش‌های مورد استفاده برای حل مساله یادگیری ساختار با محدودیت متمرکز است.

### 3. شناسایی مجموعه والد

رویکردهای امتیاز و جستجو برای یادگیری ساختار شبکه‌های بیزین روی استراتژی‌های هرس موثر تکیه می‌کنند تا تعداد مجموعه‌های والد کاندیدا برای هر متغیر کاهش یابد. مشکل شناسایی مجموعه والد، تعیین این است که کدام مجموعه والد در راحل‌های بهینه ظاهر نمی‌شوند و از این رو لازم نیست بیشتر مورد توجه قرار گیرند. متأسفانه، قوانین هرس فعلی راحل بهینه را تحت این فرض حفظ می‌کنند که ما در حال حل مساله با هیچ محدودیت جانبی روبرو نیستیم، بلکه می‌تواند در حضور محدودیت‌های کناری اشتباه باشد. برای مثال، استفاده گسترده از قانون pruning یا هرس کردن را در نظر بگیرید.

لم 2 (Teyssier and Koller 2005) :

فرض کنید  $x_i$  یک نود یا گره باشد و  $\Pi'$  و  $\Pi$  را پتانسیل مجموعه والد های  $x_i$  که  $\Pi' \subset \Pi$  و  $\sigma(x_i, \Pi') < \sigma(x_i, \Pi)$  آنگاه  $\Pi'$  مجموعه والد  $x_i$  در DAG بهینه  $G^*$  نیست.

در مساله یادگیری ساختار شبکه های بیزین (نامحدود)، این قانون اجازه می دهد  $\Pi'$ ، که یک مجموعه والد برای  $x_i$  در DAG  $G'$  است، هرس شود اگر  $\Pi$  مجموعه والد  $x_i$  با امتیاز کمتری از  $DAG\ G$  موجود باشد و  $DAG\ G$  رانیز به عنوان DAG بهینه انتخاب کند. با این حال، هنگامی که محدودیت ها در نظر گرفته می شوند، این قاعده دیگر برقرار نیست، چرا که ممکن است  $G'$  وجود یال یا محدودیت های اجدادی را برآورده کند که  $G$  انجام نمی دهد. بنابراین این تکنیک هرس نباید مورد استفاده قرار گیرد. روش ما از رویکردهای جدیدی به شناسایی مجموعه والد برای مساله یادگیری ساختاری محدود شبکه های بیزین استفاده می کند. برای مثال، قوانین زیر از محدودیت ها برای حذف راحل های غیر عملی استفاده می کنند.

(P1) اگر  $x \rightarrow y$  آنگاه میتوان هر مجموعه والد  $y$  که شامل  $x$  نباشد را هرس کرد؛

(P2) اگر  $x \leftrightarrow y$  آنگاه میتوان تمام مجموعه والد های  $y$  که شامل  $x$  باشد را هرس کرد؛

(P3) اگر  $x < y$  آنگاه میتوان مجموعه والد  $x$  که شامل  $y$  باشد را هرس کرد؛

(P4) اگر  $x \sim y$  و  $\Pi$  یک مجموعه والد  $y$  که تمام اعضای آن  $x$ ، آنگاه میتوان  $\Pi$  را هرس کرد؛

با استفاده از این قواعد برای هرس مجموعه های والد کاندیدا، هر  $DAG$  که از مجموعه والد باقی مانده ساخته شده باشد، باید تمام محدودیت های شکل  $x \rightarrow y$  و  $x \leftrightarrow y$  را برآورده کند. اگر می خواهیم فقط DAG های سازگار با برخی مرتب سازی ها را در نظر بگیریم، می توانیم به راحتی با استفاده از (P1) محدودیت  $x-y$  را به عنوان جهت یال از  $O$  در نظر بگیریم. قاعده بعدی نادرست است اما می تواند تعداد مجموعه های والد کاندید را به شدت کاهش دهد.

(P5) اگر  $\Pi$  و  $\Pi'$  مجموعه های والد  $x_i$  که  $\Pi \subset \Pi'$  و  $\lambda \geq 1$  یک ثابت که  $\lambda \sigma(x_i, \Pi) < \sigma(x_i, \Pi')$  آنگاه میتوان  $\Pi'$  را هرس کرد.

توجه داشته باشید که این قاعده هرس، معادل با لم ۲ است اگر  $\lambda = 1$  انتخاب شود. ما مجموعه والد  $\Pi'$  را مورد هرس قرار می دهیم اگر امتیاز آن به طور قابل توجهی بدتر از یکی از زیرمجموعه های آن مانند  $\Pi$  نباشد، چرا که  $\Pi'$  بعید به نظر می رسد که در راحل های بهینه برای مشکل یادگیری ساختاری شبکه های بیزین محدود ظاهر شود. انتخاب  $\lambda$  نیز مهم است؛ چرا که هرس بیش از حد (Overpruning) می تواند برای کیفیت اثر منفی در کیفیت روش بگذارد در حالی که کم هرس کردن (Underpruning) نیز ناکارآمد است. ما یک مقدار اولیه از  $\lambda$  با استفاده از فرمول محاسبه می کنیم،

که در آن  $N$  تعداد متغیرهای تصادفی،  $N$  تعداد نقاط داده،  $m_{anc}$  تعداد محدودیت های اجدادی، و  $w$  یک ثابت است.

این فرمول یک کلید اصلی را برآورده می کند. فرض کنید  $G$  و  $H$  را نداشته باشیم که DAG هایی با امتیاز بهینه و بدون محدودیت اجدادی باشد. انتظار داریم که  $G$  و  $H$  در ساختار و امتیاز نزدیک باشند اگر:

(i) تعداد نقاط داده بزرگ باشد (هر دو رویکرد شبکه واقعی یا یک شبکه معادل داشته باشند) و یا

(ii) تعداد محدودیت های نیاکانی ناچیز باشد.

بنابراین، در این موارد می خواهیم یک  $\lambda$  کوچک برای هرس مجموعه والد با امتیازات ضعیف ولی سخاوتمندانه داشته باشیم. در رویکرد خود، ما جستجو را با مقدار بالاتر از  $\lambda$  مجدداً آغاز می کنیم در صورتی که راحل های عملی را نمی توان یافت. ما همچنین مقدار  $w$  را در روش تجربی خود مشخص می کنیم.

## 4. رویکرد Hill Climbing براساس محدودیت

در این بخش، ما در مورد نحوه جستجو برای یک رامحل بهینه با یک دستوری مرتب سازی داده شده مانند  $O$  صحبت می‌کنیم که تمام محدودیت‌ها را برآورده می‌کند. به یاد می‌آورید که  $x \rightarrow y$ ،  $x \nrightarrow y$ ، و  $x - y$  همگی می‌توانند در شناسایی مجموعه والد به کار گرفته شوند. ما فرض می‌کنیم که  $O$  با تمام محدودیت‌هایی که در بخش بعدی به کار می‌رود سازگار است. در اینجا ما نشان می‌دهیم که چگونه محدودیت‌های اجدادی را کنترل کنیم. برای راحتی، ما به  $\phi(G)$  اشاره می‌کنیم که تعداد محدودیت‌های اجدادی برآورده شده توسط DAG  $G$  را نشان می‌دهد.

### تعریف (همسایه والدینی):

دو DAG مانند  $G$  و  $G'$  با گره‌های یکسان، همسایه والدینی منتسب هستند، اگر و تنها اگر مجموعه والد یک گره تنها بین  $G$  و  $G'$  متفاوت باشد.

ابتدا در الگوریتم 2 برای مرتب سازی  $O$  و DAG داده شده، که شامل محدودیت‌ها است، کمترین امتیاز را محاسبه شده و به عنوان  $G_0$  DAG همراه با مرتب سازی  $O$  به الگوریتم 1 بازگردانده می‌شود. هنگامی که ما روش را در الگوریتم 1 بر روی  $G_0$  اعمال می‌کنیم در هر مرحله از این رویکرد ما یک همسایه منتسب بهترمانند  $G'$  را برای  $G$  انتخاب کرده و سپس  $G'$  را با  $G$  جایگزین می‌کنیم. لذا گوییم  $G'$  بهبود یافته  $G$  است اگر و تنها اگر  $\phi(G_0) \geq \phi(G)$  و  $\sigma(G_0) < \sigma(G)$ .

در اینجا هدف اولیه برآورده کردن محدودیت اجدادی و سپس بهینه سازی نمره است. سپس یک لیست از مجموعه والد‌های کاندیدا با مرتب سازی صعودی نمره مرتب می‌شود.

سپس از روش Hill Climbing استفاده می‌کنیم. لیست مجموعه‌های والد کاندید با مرتب‌سازی صعودی مرتب می‌شود. برای هر مجموعه والد کاندیدای انتخابی  $p$  برای گره  $v$ ، ما  $G'$  را به عنوان همسایه والدینی  $G$  در نظر می‌گیریم. همانطور که تعداد مجموعه‌های والد کاندیدا می‌تواند بزرگ باشد، ما یک استراتژی انتخاب همسایه را اتخاذ می‌کنیم. با انجام یک جستجوی عمق-اول برای بررسی هر محدودیت اجدادی  $x \rightsquigarrow y$  در بدترین حالت، متاسفانه محاسبه  $\phi(G_0)$  می‌تواند بسیار پرهزینه باشد. با این حال، یک محدودیت  $x \rightsquigarrow y$  که در  $G$  برآورده می‌شود باید در  $G_0$  نیز برآورده شود مگر اینکه  $v$  یکی از نوادگان  $x$  و یک جد  $y$  در  $G$  باشد. به علاوه، اگر یک محدودیت  $x \rightsquigarrow y$  در  $G$  برآورده نشده باشد، باید در  $G_0$  برآورده شود در صورتی که  $v$  یک نسل از  $x$  و یکی از اجداد  $y$  باشد. به عبارت دیگر یک محدودیت اجدادی  $x \rightsquigarrow y$  که در  $G$  برآورده نشود در  $G'$  برآورده می‌شود اگر و تنها اگر نود  $v$  یک جد  $y$  و یک نسل از  $x$  باشد. از این رو، تعداد مشاهدات عمق اول را می‌توان با شرایطی کاهش داد که محدودیت‌های اجدادی برآورده شوند و نوادگان و اجداد گره‌های درگیر در محدودیت‌های اجدادی را در بر گیرد.

یک مشکل در واگذاری همسایگی والدینی این است که کوچک بوده و الگوریتم Hill Climbing می‌تواند در مینیمم محلی با کیفیت پایین در آن گیر کند. ما این مساله را با معرفی پیاده‌روی تصادفی (walkProb) و فهرست tabu حل می‌کنیم. وقتی Hill Climbing به یک حداقل محلی می‌رسد، با احتمال کمی به یک رامحل تصادفی ساده حرکت می‌کند. گره ای که مجموعه والد آن تحت‌تاثیر قرار می‌گیرند، پس از سه تکرار بعدی Hill Climbing ممنوع اعلام می‌شود، بنابراین تغییر بلافاصله برگردانده نمی‌شود. (در حالی که یک‌گره ممنوع باشد نمی‌تواند والد خود را تخصیص دهد)

---

**Algorithm 1:** hillClimbDAG( $G, \mathcal{O}$ )

---

```
allParents  $\leftarrow$  allParentSets();           /* sorted by increasing score */
while true do
  for  $p$  in allParents do
     $x \leftarrow \text{child}(p)$ ;
    if not  $\text{tabu}(x)$  and  $\text{feasible}(p, \mathcal{O})$  then
       $G' \leftarrow G$ ;
       $G'.\text{parentOf}(x) \leftarrow p$ ;
      if  $G'$  improves  $G$  then
         $G \leftarrow G'$ ;
        break;
      end if
    end if
  end for
  if no improvement found then
    if  $\text{random}(0, 1) < \text{walkProb}$  then
       $p \leftarrow$  random feasible parent set;
       $x \leftarrow \text{child}(p)$ ;
       $G.\text{parentOf}(x) \leftarrow p$ ;
      tabu  $x$  for 3 iterations;
    else
      break;
    end if
  end if
end while
return  $G$ ;
```

---

---

**Algorithm 2:** bestDAGForOrdering( $\mathcal{O}$ )

---

```
 $G_0 \leftarrow \text{initialDAG}(\mathcal{O})$ ;
return hillClimbDAG( $G_0, \mathcal{O}$ );
```

---

**الگوریتم 1: شبیه کد Hill Climbing**

- ورودی: DAG بهینه  $G_0$  دارای بهترین امتیاز به همراه مرتب سازی **Ordering (O)**
- عملیات: حذف مجموعه والد‌های کاندیدای مضاعف/بخش اول/بر اساس امتیاز و آزمون درستی بهینه سراسری/بخش دوم)
- خروجی: DAG بهینه  $G$  دارای مجموعه والد‌های بهینه

**الگوریتم 2: محاسبه بهترین امتیاز مرتب سازی**

- ورودی: DAG  $G$  به همراه محدودیت ها و مرتب سازی **Ordering(O)**
- عملیات: محاسبه ی امتیاز تمام مجموعه های والد و DAG های آنها
- خروجی: DAG های بهینه  $G_0$  دارای بهترین امتیاز به همراه مرتب سازی **Ordering (O)**

## 5. جستجو براساس مرتب سازی Ordering-based Search

در این بخش ما بر روی Hill Climbing بر روی فضای مرتب سازی topological متمرکز می‌شویم. امتیاز یک مرتب سازی  $O$  حداقل مقدار  $\sigma(G)$  برای DAG های  $G$  سازگار با مرتب سازی  $O$  و تمامی محدودیت‌ها است. همانطور که پیدا کردن حداقل امتیاز دشوار است، ما بهترین مقدار یافت شده توسط الگوریتم ۲ را به عنوان امتیاز مرتب سازی  $O$  در نظر می‌گیریم. ما تقریباً همان استراتژی جستجو و همسایگی را که در MINOBS (لی و ون beek، ۲۰۱۷) که از همسایگی وارد شده و همسایگی مجاور آن استفاده می‌کنند، دنبال می‌کنیم. به بیان ساده،  $O'$  یک همسایه ورودی (insert neighbours) از  $O$  است اگر از عناصر و مرتب سازی  $O$  باشد و آن را به یک شاخص جدید اضافه کند.

به عنوان مثال  $\{X_1, X_2, X_3, X_4\}$  و  $\{X_1, X_4, X_2, X_3\}$  همسایه ورودی هستند چرا که یک همسایه مجاور از یک مرتب سازی  $O$  ناشی از مبادله یک عنصر با عنصر قبلی آن است. به عنوان مثال دیگر  $\{X_1, X_2, X_3, X_4\}$  و  $\{X_1, X_2, X_4, X_3\}$ . همسایه ورودی را می‌توان با استفاده از مجموعه‌ای از حرکت‌های مجاور پیمود. هر حرکت تبادل مجاور (swap-adjacent) تنها بر انتخاب مجموعه والد برای دو عنصر تعویض شده در زمانی که هیچ محدودیت اضافی وجود ندارد، تأثیر می‌گذارد، اما هنگام وجود محدودیت‌های جانبی اثر گذار نیست. لذا ما استراتژی زیر را برای موثر بودن پیدا کردیم. فرض کنید مرتب سازی  $O = \{x_1, \dots, x_i, x_{i+1}, \dots, x_n\}$  داده شده و  $G$  به عنوان بهترین DAG به همراه محدودیت هاب‌دست آمده باشد. حال فرض کنید که عنصر  $i$  با عنصر  $i+1$  جابجا شود و ما می‌خواهیم بهترین حالت ممکن با  $O' = \{x_1, \dots, x_{i+1}, x_i, \dots, x_n\}$  را بیابیم. ما دریافتیم که استفاده از  $G$  به عنوان نقطه شروع اولیه برای Hill Climbing بر روی  $O'$  زمان اجرا را بهبود می‌بخشد، چرا که  $G$  همه محدودیت‌های اجدادی را برآورده می‌کند و احتمالاً دارای کیفیت بالا است. اگر مجموعه والد های  $x_{i+1}$  و در  $G$  حاوی  $x_i$  باشد،  $G$  تحت  $O'$  پذیرفتنی نیست، اما ما این را با جایگزین کردن والدین  $x_{i+1}$  با مجموعه والد های با پایین‌ترین امتیاز ممکن تحت  $O'$  جایگزین می‌کنیم.

## 6. ارزیابی تجربی

ما در آزمایش‌ها خود روش پیشنهادی خود را با نشان دادن MINOBSx در برابر CaMML مقایسه می‌کنیم. CaMML برای مقایسه انتخاب شد چون به طور گسترده در زمینه‌های کاربردی استفاده می‌شود (مثلاً فلورس و همکارانش (۲۰۱۱)، Kennett و همکارانش (۲۰۱۳)، Sesen و همکارانش (۲۰۱۳) از آن استفاده کردند) و همچنین مبتنی بر رویکرد تصادفی امتیاز و جستجو است. توجه داشتن به این مسئله مهم است که مساله یادگیری بدون محدودیت‌های اجدادی آسان‌تر است (اضافه کردن هر کدام از محدودیت‌های دیگر به طور کلی عملکرد را بهبود می‌بخشد). بنابراین ما CaMML را برای مقایسه MINOBSx در برابر روش‌هایی که نمی‌توانستند محدودیت‌های اجدادی را کنترل کنند، انتخاب کردیم. متأسفانه کد منبع برای درخت EC در دسترس نبود.

نمونه‌های آزمایشی ما شامل همه شبکه‌های کوچک و متوسط در مخزن شبکه Bayesian است که بزرگ‌ترین آن‌ها barley (۴۸ نود) است. ما به طور تصادفی ۶ مجموعه داده کوچک و ۶ مجموعه داده بزرگ را از توزیع‌های احتمالی مشترک شبکه‌های واقعیت زمینی این داده‌ها نمونه‌برداری کردیم. دو مجموعه از آزمایش‌ها اجرا شدند: (۱) تنها اعمال محدودیت‌های اجدادی و (۲) اعمال محدودیت‌های مختلف. برای هر مجموعه‌ای از آزمایش‌ها، ما ۴ درصد ثابت را انتخاب کردیم و ۵ مجموعه از محدودیت را در آن درصد از شبکه واقعی (ground truth network) نمونه‌گیری کردیم. برای درصد  $p$  ما از محدودیت‌های موجود در روش زیر نمونه برداری کردیم:



- ما  $p\%$  از همه یال‌های جهت‌دار در شبکه واقعی را انتخاب می‌کنیم. برای هر یال،  $x-y$  احتمال  $\frac{1}{2}$  را در نظر می‌گیریم، در غیر این صورت  $x-y$  را گزارش می‌کنیم.
- ما  $p\%$  از تمام جفت‌ها  $(y,x)$  را که در شبکه واقعی هیچ یال‌های جهت‌داری بین آنها وجود ندارد، انتخاب و  $x \rightarrow y$  را گزارش می‌کنیم.
- ما  $p\%$  از همه زوج‌های  $(y,x)$  را که یک مسیر جهت‌دار بین  $x$  و  $y$  در شبکه واقعی وجود دارد را انتخاب و  $x \leftarrow y$  را گزارش می‌کنیم.
- ما از مرتب‌سازی توپولوژیک برای بازیابی نظم دلخواه از شبکه ی واقعی استفاده کرده و  $p\%$  از تمام  $(n_2)$  محدودیت مرتب سازهای ممکن را انتخاب و  $x < y$  را برای  $O$  گزارش می‌کنیم.

وقتی MINOBSx و CaMML را مقایسه می‌کنیم، محدودیت‌های نبود یال  $x \rightarrow y$  را حذف می‌کنیم چون CaMML این محدودیت‌ها را قبول نمی‌کند. برای هر مجموعه داده و هر مجموعه محدودیت، ما هر دو روش MINOBSx و CaMML را پیاده و مجموعه داده‌ها و محدودیت‌ها را به عنوان ورودی ارائه کردیم.

## 6.1 تنظیمات

تمام آزمایش‌ها بر روی یک هسته واحد از پردازنده اینتل Intel "Broadwell" E5-2683 v4 CPU @ 2.1 Gh با یک محدوده حافظه پردازشی ۵۱۲ مگابایت برای شبکه‌های کوچک و ۴ گیگابایت برای شبکه‌های متوسط اجرا شدند.

با توجه به محدود بودن فضای دیسک ذخیره سازی، امتیاز مجموعه والدین با استفاده از فرمول کوکران و روش GOBNILP تا سه والد محاسبه شد. زمان اجرای GOBNILP در زمان اجرای MINOBSx در نتایج آن محاسبه شده است. این روش برای 50 دوره در شبکه‌های کوچک و 10 دوره روی شبکه‌های متوسط اجرا شد. پارامتری  $w$  نیز با استفاده از نمونه‌های  $barle, child$  و سرطان تنظیم شده است.

CaMML تحت تنظیمات پیش‌فرض خود در جاوا اجرا شد. در حالی که MINOBSx در C++ اجرا می‌شود. تمامی محدودیت‌ها مربوط به CaMML با سطح اعتماد 1.0 (محدودیت سخت) به جز محدودیت‌های اجدادی مشخص شدند، که به طور شگفت‌انگیز، هنگامی که سطح اعتماد برای محدودیت‌های اجدادی با تغییر اعتماد به 0.999 برای محدودیت‌های اجدادی مشخص شد، CaMML توانست برخی نمونه‌ها را کاملاً حل کند که در غیر این صورت قادر به یافتن راه‌حلی برای آن نبود.

## 6.2 نتایج

روش MINOBSx توانست راه حل‌های پذیرفتنی شامل تمام محدودیت‌ها را برای تمامی نمونه‌ها بدست آورد. روش CaMML قادر بود به طور مداوم بیش‌ترین محدودیت را بر روی شبکه‌های کوچک داشته باشد، اما در همه موارد بسیار ضعیف عمل کرد. نتایج به طور صریح در جدول نشان داده شده است.

ما همچنین کیفیت شبکه‌های یادگیری (learn) شده توسط روش MINOBSx را در برابر شبکه‌های واقعی زمین مقایسه می‌کنیم. ما کیفیت شبکه‌های یادگیری (learn) شده توسط روش CaMML را در برابر شبکه‌های واقعی مقایسه نمی‌کنیم. چراکه این دو روش از توابع امتیازدهی مختلف استفاده می‌کنند، که می‌تواند تأثیر زیادی بر روی نتایج داشته باشد. برای مواردی که تنها محدودیت‌های اجدادی بود، ما به طور مستقیم نتایج تولید شده در آزمایش‌های گروه قبلی را تجزیه و تحلیل کردیم؛ با این حال، برای مواردی با محدودیت‌های مختلف، ما روش MINOBSx را بر روی مجموعه‌های محدودیت اجرا کردیم که شامل محدودیت نبود یال بودند. ما تعداد یال‌های گمشده، اضافی و معکوس (missing/extra/reverse) و فاصله مداخله سازه‌ای (SID) بین شبکه‌های واقعیت زمینی و شبکه یادگیری شده را گزارش می‌کنیم (که تفاوت در علیت را اندازه‌گیری می‌کند).

instance	N	%	MINOBSx			CaMML		
			% feasible	% sat	t (seconds)	% feasible	% sat	t (seconds)
asia 8 variables 18 params	250	10 / 5	100 / 100	100 / 100	1.1 / 0.5	100 / 100	100 / 100	5.8 / 5.4
		25 / 10	100 / 100	100 / 100	1.3 / 0.5	100 / 100	100 / 100	6.3 / 5.5
		50 / 15	100 / 100	100 / 100	0.9 / 0.3	100 / 100	100 / 100	6.8 / 5.9
		100 / 20	100 / 100	100 / 100	0.5 / 0.2	100 / 100	100 / 100	8.3 / 5.7
	1000	10 / 5	100 / 100	100 / 100	0.9 / 0.4	100 / 100	100 / 100	5.5 / 5.0
		25 / 10	100 / 100	100 / 100	1.1 / 0.4	100 / 100	100 / 100	6.0 / 5.3
		50 / 15	100 / 100	100 / 100	0.7 / 0.3	100 / 96.7	100 / 99.7	6.3 / 5.6
		100 / 20	100 / 100	100 / 100	0.4 / 0.2	100 / 100	100 / 100	7.3 / 5.6
insurance 27 variables 984 params	500	10 / 5	100 / 100	100 / 100	180.5 / 104.9	50.0 / 70.0	95.9 / 99.0	439.5 / 325.3
		25 / 10	100 / 100	100 / 100	318.9 / 56.5	56.7 / 50.0	98.0 / 98.9	723.9 / 385.0
		50 / 15	100 / 100	100 / 100	328.7 / 52.8	30.0 / 33.3	98.5 / 98.1	1165.6 / 485.2
		100 / 20	100 / 100	100 / 100	292.5 / 37.4	0 / 53.3	98.1 / 99.6	2052.3 / 571.7
	2000	10 / 5	100 / 100	100 / 100	124.0 / 88.3	0 / 53.3	78.8 / 98.1	438.5 / 309.8
		25 / 10	100 / 100	100 / 100	236.3 / 49.6	16.7 / 23.3	92.4 / 96.8	748.6 / 393.2
		50 / 15	100 / 100	100 / 100	251.5 / 48.2	3.3 / 10.0	94.4 / 96.6	1175.2 / 487.9
		100 / 20	100 / 100	100 / 100	233.1 / 33.4	0 / 10.0	95.6 / 98.8	1956.8 / 571.1
barley 48 variables 114005 params	2000	10 / 5	100 / 100	100 / 100	2321.4 / 5866.8	0 / 0	70.3 / 89.3	19824.8 / 11666.1
		25 / 10	100 / 100	100 / 100	4228.9 / 2941.3	0 / 0	74.4 / 93.6	37034.3 / 14864.9
		50 / 15	100 / 100	100 / 100	7163.0 / 3518.9	0 / 0	73.9 / 95.0	70433.0 / 20339.2
		100 / 20	100 / 100	100 / 100	7246.6 / 1806.3	0 / 0	80.9 / 96.3	114036.7 / 22366.9
	8000	10 / 5	100 / 100	100 / 100	4761.1 / 6032.7	0 / 0	44.0 / 82.8	18092.6 / 10759.6
		25 / 10	100 / 100	100 / 100	4063.8 / 3620.0	0 / 0	52.5 / 91.8	35308.3 / 14477.5
		50 / 15	100 / 100	100 / 100	5137.8 / 3022.8	0 / 0	54.0 / 95.1	64893.5 / 18142.0
		100 / 20	100 / 100	100 / 100	5675.6 / 1638.8	0 / 0	53.4 / 95.1	111338.4 / 21184.4

جدول 1: نتایج عملکرد برای محدودیت‌های اجدادی تنها (اولین عدد در هر جفت) و با محدودیت‌های مختلف (عدد دوم در هر جفت)

- %: ثابت درصد مورد استفاده برای محدودیت نمونه‌ها، درصد مواردی که راه حل رضایت همه محدودیت‌های تحمیل شده
- % feasible: درصد قابل اجرا، درصد مواردی که راه حل آن توسط رضایت همه محدودیت‌ها تحمیل شده
- % sat: درصد محدودیت‌های برآورده شده توسط محدودیت‌های تحمیل شده
- t: زمان در حال اجرا و مورد نیاز برنامه
- N: تعداد مشاهدات
- سلول‌های برجسته نمایانگر برآورده نشدن تمامی محدودیت‌ها

instance	N	%	Missing	Extra	Reversed	SID	Score (BDeu)
asia 8 variables 18 parameters	250	0*	1.5	1.7	1.0	12.2	0%
		10 / 5	1.4 / 1.4	1.6 / 1.6	0.7 / 0.9	10.3 / 11.1	0.0% / 0.0%
		25 / 10	1.2 / 1.4	1.8 / 1.6	0.5 / 0.6	7.2 / 8.9	0.1% / 0.1%
		50 / 15	1.0 / 0.8	2.0 / 1.4	0.3 / 0.4	4.3 / 4.4	0.2% / 0.3%
		100 / 20	0.5 / 0.7	1.7 / 1.1	0.0 / 0.2	1.8 / 3.9	0.3% / 0.3%
	1000	0*	0.8	0.3	1	9.0	0%
		10 / 5	0.7 / 0.8	0.4 / 0.4	0.9 / 1.1	7.3 / 9.0	0.0% / 0.0%
		25 / 10	0.4 / 0.5	0.5 / 0.3	0.4 / 0.8	4.2 / 6.4	0.0% / 0.0%
		50 / 15	0.2 / 0.3	0.4 / 0.4	0.0 / 0.5	0.4 / 3.6	0.0% / 0.0%
		100 / 20	0.0 / 0.2	0.3 / 0.3	0.0 / 0.4	0 / 3.1	0.0% / 0.0%
child 20 variables 230 parameters	500	0*	5.3	1.0	3.0	115.7	0%
		10 / 5	4.8 / 4.8	1.1 / 0.8	1.9 / 1.3	91.4 / 82.6	0.1% / 0.2%
		25 / 10	4.7 / 4.3	1.9 / 1.6	1.6 / 1.8	93.9 / 79.4	0.2% / 0.3%
		50 / 15	3.9 / 4.2	1.4 / 1.2	1.7 / 0.7	76.1 / 69.9	0.3% / 0.4%
		100 / 20	2.2 / 3.6	2.2 / 0.8	0.0 / 0.3	35.8 / 57.6	0.9% / 0.4%
	2000	0*	1.7	0.2	3.5	79.2	0%
		10 / 5	1.5 / 1.3	0.2 / 0.2	0.5 / 0.1	26.0 / 20.8	0.0% / 0.0%
		25 / 10	0.7 / 1.0	0.3 / 0.3	0.3 / 0.5	12.1 / 18.0	0.0% / 0.0%
		50 / 15	0.7 / 1.0	0.3 / 0.3	0.5 / 0.0	12.2 / 16.2	0.0% / 0.0%
		100 / 20	0.2 / 1.0	0.3 / 0.1	0.0 / 0.0	2.5 / 16.6	0.1% / 0.0%
alarm 37 variables 509 parameters	1000	0*	2.2	5.8	1.3	45.7	0%
		10 / 5	2.0 / 1.6	6.2 / 5.5	1.1 / 1.6	34.7 / 46.4	0.0% / 0.1%
		25 / 10	2.0 / 1.8	6.3 / 5.4	0.7 / 0.8	27.7 / 32.2	0.1% / 0.1%
		50 / 15	2.0 / 1.5	6.1 / 5.0	0.3 / 0.6	22.4 / 27.7	0.1% / 0.2%
		100 / 20	2.0 / 1.5	6.2 / 4.4	0.0 / 0.1	18.0 / 18.3	0.1% / 0.2%
	4000	0*	2.0	3.2	1.8	39.5	0%
		10 / 5	2.0 / 1.6	4.6 / 4.5	0.6 / 1.2	24.9 / 38.8	0.0% / 0.0%
		25 / 10	2.0 / 1.8	4.5 / 4.3	0.3 / 0.6	20.1 / 28.0	0.0% / 0.0%
		50 / 15	2.0 / 1.5	4.1 / 4.2	0.0 / 0.4	18.0 / 22.3	0.0% / 0.1%
		100 / 20	1.7 / 1.4	4.2 / 3.7	0.0 / 0.3	12.3 / 20.4	0.0% / 0.1%
barley 48 variables 114005 parameters	2000	0*	32.3	8.2	9.7	949.5	0%
		10 / 5	33.3 / 31.7	14.4 / 12.2	5.1 / 4.4	792.9 / 756.7	0.6% / 1.4%
		25 / 10	31.9 / 31.0	15.6 / 13.8	5.3 / 4.8	802.6 / 741.5	0.9% / 1.7%
		50 / 15	31.0 / 27.5	17.4 / 11.3	3.0 / 3.2	699.4 / 666.9	1.4% / 2.9%
		100 / 20	30.2 / 26.4	19.5 / 11.8	0.0 / 1.5	619.3 / 628.1	2.4% / 3.9%
	8000	0*	25.5	3.7	9.7	794.7	0%
		10 / 5	25.6 / 24.6	8.9 / 8.0	5.3 / 5.2	636.6 / 625.4	0.3% / 0.8%
		25 / 10	25.0 / 24.0	10.4 / 8.8	5.5 / 4.3	644.4 / 584.7	0.4% / 0.9%
		50 / 15	22.1 / 20.5	9.2 / 7.6	3.3 / 1.9	541.7 / 487.4	0.6% / 1.4%
		100 / 20	20.8 / 19.3	12.0 / 7.0	0.0 / 1.6	457.2 / 507.2	0.9% / 1.8%

**جدول 2:** نتایج عملکرد برای محدودیت‌های اجدادی تنها (اولین عدد در هر جفت) و با محدودیت‌های مختلف (عدد دوم در هر جفت)

- نتایج عملکرد برای محدودیت‌های اجدادی (تعداد اول در هر جفت) و با محدودیت‌های مختلف (شماره دوم در هر جفت)
- ردیف 0\* نشان داده شده زیر ستون٪ نمایانگر راه حل‌های مطلوب تولید شده توسط GOBNILP بدون محدودیت‌های جانبی

ما همچنین درصد اختلاف بین امتیاز BDeu شبکه‌های یادگیری (learn) شده و امتیاز بهینه تولید شده توسط GOBNILP در نمونه بدون محدودیت جانبی را گزارش می‌کنیم. نتایج برای ۴ شبکه از اندازه‌های مختلف در جدول ۲ نشان داده شده‌اند. با این حال، شبکه‌های دیگر نتایج مشابهی را ایجاد کرده‌اند.

از این نتایج، به نظر می‌رسد که به ویژه با افزایش تعداد متغیرها، روش MINOBSx بسیار قویتر از روش CaMML است. حتی وقتی روش CaMML به طور قابل‌توجهی زمان بیشتری را نسبت به زمان روش MINOBSx صرف می‌کند، اما اغلب قادر به یافتن راحل‌های پذیرفتنی نیست. همچنین درصد اختلاف بین امتیازات BDeu در مساله همراه با محدودیت و مساله بدون محدودیت کوچک است و هرگز بیش از 4% نیست. از این رو در بدترین حالت، جواب‌های تولید شده توسط MINOBSx در محدوده خطای 4% قرار دارند.

هنگامی که ما تاثیر محدودیت‌های اجدادی بر کیفیت راحل را تجزیه و تحلیل می‌کنیم، می‌بینیم که تعدادیال‌های گم‌شده و معکوس تمایل به کاهش دارد در حالی که تعداد یال‌های اضافی تغییر نمی‌کند یا بدتر می‌شود. با این حال، در برخی موارد تعداد یال‌های از دست رفته بهبود نیافته است، حتی هنگامی که 100% از محدودیت‌های اجدادی نیز اضافه شده‌است. به نظر می‌رسد که تعداد کمی از محدودیت‌های مختلف بهبود قابل‌توجه و پایداری را برای کم کردن یال‌های بیشتر ارایه می‌دهند. دلیل احتمالی این است که یال وجود دارد. و محدودیت‌های نبود یال می‌توانند مستقیماً یک یال یا یال اضافی را ثابت کنند در حالی که محدودیت‌های اجدادی مبهم هستند. اگر یک مسیر نادرست برای برآورده سازی محدودیت اجدادی مورد استفاده قرار گیرد، ممکن است باعث ایجاد یال‌های اضافی شود در حالی که تعداد یال‌های گم شده را بهبود نمی‌دهد. از سوی دیگر به نظر می‌رسد که محدودیت‌های اجدادی به تنهایی به طور قابل‌توجهی (SID) را بهبود می‌بخشد. درحالی که محدودیت‌های اجدادی منجر به دلایل غیر مستقیم می‌شوند و (SID) تفاوت در اظهارات علی را اندازه‌گیری می‌کند، این انتظار را نیز می‌توان داشت.

یک دام یا نقص که ما یادداشت می‌کنیم این است که به دلیل حد پایین والد ۳، MINOBSx قادر به بازیابی شبکه واقعی (ground truth network) در برخی موارد نیست، در حالی که CaMML صریحاً یک حد برای تعداد والد‌ها را تعیین نمی‌کند. این امر در نتایج alarm که شامل یک نود با ۴ والد است، مشاهده می‌شود. با این حال، این به طور کلی مهم نیست چراکه مجموعه‌های والد بزرگ منجر به مدل‌های پیچیده می‌شوند که بعید به نظر می‌رسد که در راحل‌های بهینه ظاهر شوند، به خصوص زمانی که مقدار داده کوچک باشد.

## 7. نتیجه‌گیری

ما یک روش جدید را برای ترکیب محدودیت‌های دانش قبلی (prior) به یک الگوریتم جستجوی محلی برای یادگیری ساختار شبکه بی‌زی، شامل محدودیت‌های مصنوعی غیر همگن ارائه می‌کنیم. در حالی که روش‌های دقیق قبلی می‌توانند به بیست متغیر تصادفی رسیدگی کنند، نشان می‌دهیم که روش جستجوی تصادفی ما قادر است تا به حدود پنجاه متغیر تصادفی در حین تولید شبکه‌های با کیفیت بالا، رسیدگی کند. در مقایسه با الگوریتم‌های مورد استفاده، CaMML یک نرم‌افزار است که به طور گسترده توسط محققان در زمینه‌های کاربردی مورد استفاده قرار می‌گیرد. روش پیشنهادی ما عملکرد بسیار قوی و سازگار در شبکه‌ها، حتی با بیش از 20 گره، را نشان می‌دهد.

برای کارهای آینده، تکنیک‌های مشابهی که در این مقاله ارائه شده‌اند، برای رسیدگی بر استفاده موثر از محدودیت‌های غیرقابل تجزیه، ممکن است مفید واقع شوند. یکی از این نمونه‌ها، d-جدایی (d-separation) است، که می‌تواند برای تضمین و اثبات روابط استقلال شرطی بین متغیرها استفاده شود.

## 7.1. سپاس گذاری ها

این تحقیق در بخشی از Compute Canada ، WestGrid پشتیبانی و با یک جایزه NSERCUSRA حمایت شد.

### منابع

مجموعه مقالات و تحقیقات یادگیری ماشین جلد ۷۲، ۲۲۵ - ۲۳۶، ۲۰۱۸ - ۲۰۱۸

P. Antal, G. Fannes, D. Timmerman, Y. Moreau, and B. De Moor. Using literature and data to learn BN as clinical models of ovarian tumors. *Artificial Intelligence in Medicine*, 30 (3):257–281, 2004.

M. Bartlett and J. Cussens. Integer linear programming for the BN structure learning problem. *Artificial Intelligence*, 244:258–271, 2017.

E. Y.-J. Chen, Y. Shen, A. Choi, and A. Darwiche. Learning BNs with ancestral constraints. In *Advances in Neural Information Processing Systems*, pages 2325–2333, 2016.

T.-T. Chen and S.-S. Leu. Fall risk assessment of cantilever bridge projects using BN. *Safety science*, 70:161–171, 2014.

D. M. Chickering, C. Meek, and D. Heckerman. Large-sample learning of BNs is NP-hard. In *Proceedings of the 19th Conference on Uncertainty in Artificial Intelligence*, pages 124–133, 2003.

S. Dasgupta. Learning polytrees. In *Proceedings of the Fifteenth Conference on Uncertainty in Artificial Intelligence*, pages 134–141, 1999.

L. M. de Campos and J. G. Castellano. BN learning using structural restrictions. *International Journal of Approximate Reasoning*, 45:233–254, 2007.

M. J. Flores, A. E. Nicholson, A. Brunskill, K. B. Korb, and S. Mascaro. Incorporating expert knowledge when learning BN structure: a medical case study. *Artificial intelligence in medicine*, 53(3):181–204, 2011.

N. Friedman, M. Linial, I. Nachman, and D. Pe’er. Using BNs to analyze expression data. *Journal of computational biology*, 7(3-4):601–620, 2000.

R. Giordano, D. D’Agostino, C. Apollonio, N. Lamaddalena, and M. Vurro. Bayesian belief network to support conflict analysis for groundwater protection: the case of the Apulia region. *Journal of environmental management*, 115:136–146, 2013.

- D. Heckerman, D. Geiger, and D. M. Chickering. The combination of knowledge and statistical data. *Machine Learning*, 20:197–243, 1995.
- R. J. Kennett, K. B. Korb, and A. E. Nicholson. Seabreeze prediction using BNs. In *Pacific-Asia Conference on Knowledge Discovery and Data Mining*, pages 148–153. Springer, 2001.
- K. B. Korb and A. E. Nicholson. *Bayesian Artificial Intelligence*. CRC press, 2010.
- C. Lee and P. van Beek. Metaheuristics for score-and-search BNs structure learning. In *Proceedings of the 30th Canadian Conference on Artificial Intelligence*, pages 129–141, 2017. Available as: LNCS 10233.
- S.-S. Leu and C.-M. Chang. BN-based safety risk assessment for steel construction projects. *Accident Analysis & Prevention*, 54:122–133, 2013.
- T.-Y. Ma, J. Y. Chow, and J. Xu. Causal structure learning for travel mode choice using structural restrictions and model averaging algorithm. *Transportmetrica A: Transport Science*, 13(4):299–325, 2017.
- D. Oyen, B. Anderson, and C. M. Anderson-Cook. BNs with prior knowledge for malware phylogenetics. In *AAAI Workshop: Artificial Intelligence for Cyber Security*, 2016.
- J. Peters and P. Buhlmann. Structural intervention distance for evaluating causal graphs. *Neural computation*, 27(3):771–799, 2015.
- C. A. Pollino, O. Woodberry, A. Nicholson, K. Korb, and B. T. Hart. Parameterisation and evaluation of a BN for use in an ecological risk assessment. *Environmental Modelling & Software*, 22(8):1140–1152, 2007.
- S., O. S., ahin, F. Ulengin, and B. Ulengin. A Bayesian causal map for inflation analysis: The case of Turkey. *European Journal of Operational Research*, 175(2):1268–1284, 2006.
- G. Schwarz. Estimating the dimension of a model. *The Annals of Statistics*, 6:461–464, 1978.
- M.B.Sesen, A.E.Nicholson, R.Banares-Alcantara, T.Kadir, and M.Brady. BNs clinical decision support in lung cancer care. *PloS one*, 8(12):e82349, 2013.
- M. Teyssier and D. Koller. Ordering-based search: A simple and effective algorithm for learning BNs. In *Proceedings of the 21st Conference on Uncertainty in Artificial Intelligence*, pages 548–549, 2005.
- I. Tsamardinos, L. E. Brown, and C. F. Aliferis. The max-min hill-climbing BN structure learning. *Machine learning*, 65(1):31–78, 2006.